UNIVERSIDAD PERUANA
CAYETANO HEREDIA

Estadística y Probabilidades para Ingeniería

CLASE 2:

CLASIFICACIÓN Y PRESENTACIÓN DE DATOS

- **Resultado de aprendizaje:**

  Identificar la forma de clasificar y presentar los datos mediante tablas de frecuencias y gráficos según la naturaleza de las variables.

  .

- **Contenido**
  - Clasificación y presentación de datos
  - Tablas de distribución de frecuencias
  - Gráficos: Histograma, caja y bigote, diagrama de dispersión

CLASIFICACIÓN Y PRESENTACIÓN DE LOS DATOS

Enf. Pulmonar
Diabetes Mellitus
Enf. Cardiovascular
Enf. Renal
Cáncer
Enf. Pulmonar
Cáncer
Enf. Pulmonar
Diabetes Mellitus
Enf. Cardiovascular
Diabetes Mellitus
Enf. Renal
Enf. Cardiovascular
Diabetes Mellitus
Enf. Pulmonar
Cáncer
Enf. Renal
Diabetes Mellitus
Enf. Cardiovascular
Enf. Pulmonar
Diabetes Mellitus
Enf. Renal
Enf. Pulmonar
Enf. Renal
Cáncer
Diabetes Mellitus
Enf. Pulmonar
Enf. Renal
Diabetes Mellitus
Enf. Pulmonar
Cáncer
Enf. Pulmonar
Diabetes Mellitus
Enf. Cardiovascular
Diabetes Mellitus

Actividad 1: Lluvia de ideas

¿De qué manera podemos presentar estos datos para obtener información relevante para tomar decisiones?

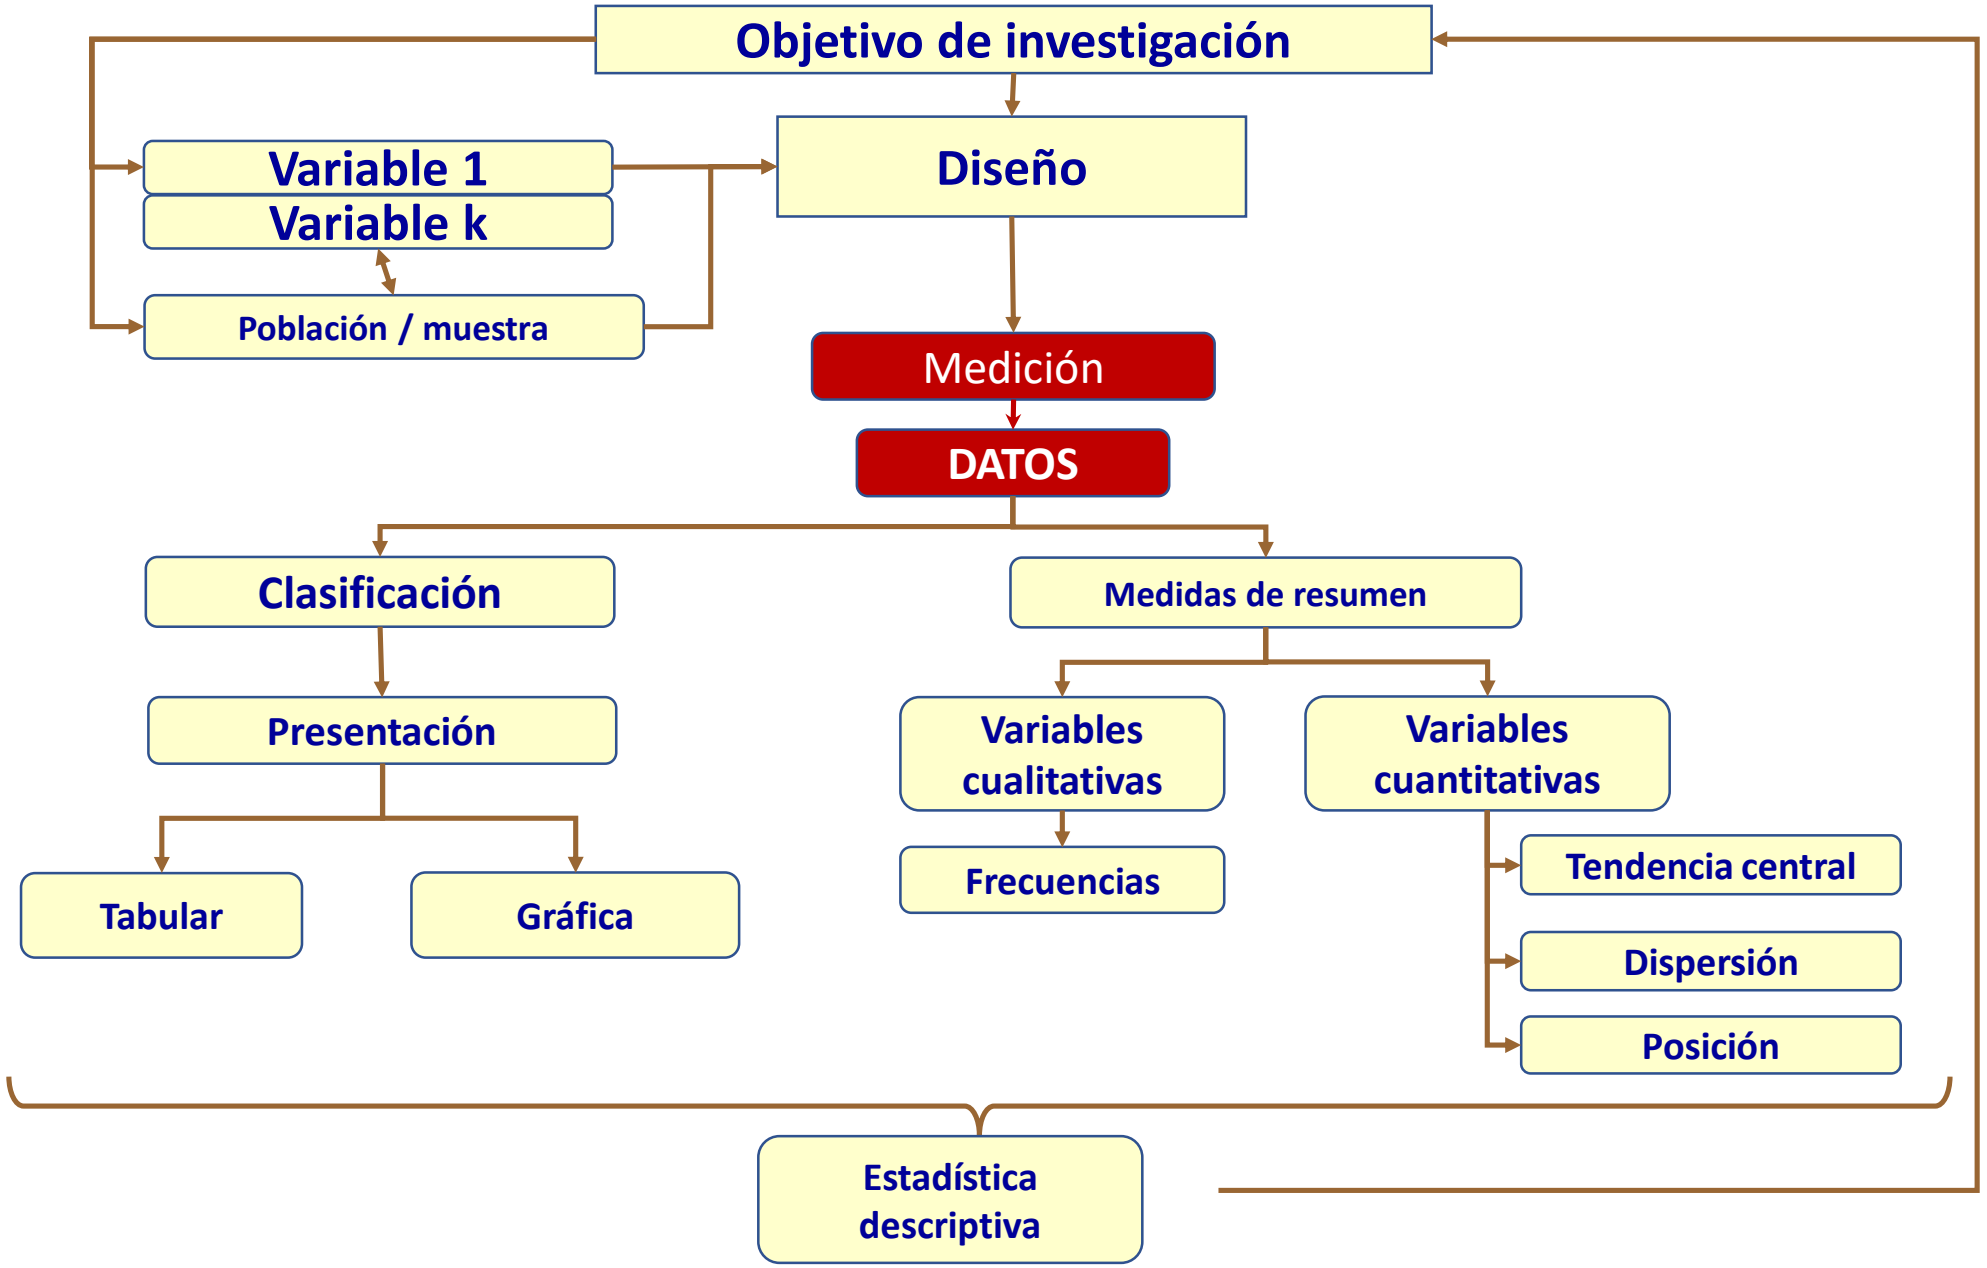
Objetivo de investigación
Variable 1
Variable k
Población / muestra
Diseño
Medición
DATOS
Clasificación
Presentación
Tabular
Gráfica
Medidas de resumen
Variables cualitativas
Frecuencias
Variables cuantitativas
Tendencia central
Dispersión
Posición
Estadística descriptiva

CLASIFICACIÓN DE DATOS

La *clasificación de datos* consiste en agrupar los datos recolectados en categorías o clases.

Cada *clase* está conformada por un categoría o un intervalo de valores de la variable.

El número de clases depende de:

- Tipo de variable, y
- el número de datos.

El número de datos reunidos en una clase se denomina *frecuencia* de la clase; que puede expresarse en números absolutos o relativos.

Cuando las clases se listan en una columna, junto con sus frecuencias, se tiene una *distribución de frecuencias*, y su presentación se conoce como una *tabla de distribución de frecuencias*.

Comorbilidad	**Frecuencia**	**Porcentaje**
Diabetes Mellitus	236	39.0
Enfermedad Cardiovascular	287	47.4
Enfermedad Pulmonar Crónica	32	5.3
Enfermedad Renal	29	4.8
Cáncer	21	3.5
Total	**605**	**100.0**

PRESENTACIÓN DE DATOS

La *presentación de los datos* consiste en la organización de los datos de modo tal que permita:

- Explorar y describir los datos.
- Calcular medidas estadísticas.

La presentación de los datos puede hacerse de dos formas:

- Tabular.
- Gráfica.

PRESENTACIÓN TABULAR

Es la presentación de los datos en *tablas* estadísticas.

Una tabla es un conjunto de filas y un conjunto de columnas que se entrecruzan, conformando celdas donde se presentan los datos.

Las tablas pueden ser:

- De una entrada, cuando la distribución de los datos corresponde a una variable.
- De doble entrada, cuando la distribución corresponde a dos o más variables.

PRESENTACIÓN TABULAR

Actividad 2: ¿Qué partes identificas en la tabla?

TITULO

Table 1: Demographics and baseline characteristics of patients infected with 2019-nCoV

MATRIZ

CUERPO

Characteristics	All patients (n=41)	ICU care (n=13)	No ICU care (n=28)	p value
Age, years	49·0 (41·0–58·0)	49·0 (41·0–61·0)	49·0 (41·0–57·5)	0·60
Sex	..	..	..	0·24
Men	30 (73%)	11 (85%)	19 (68%)	..
Women	11 (27%)	2 (15%)	9 (32%)	..
Huanan seafood market exposure	27 (66%)	9 (69%)	18 (64%)	0·75

Data are median (IQR), n (%), or n/N (%), where N is the total number of patients with available data. p values comparing ICU care and no ICU care are from χ^2 test, Fisher's exact test, or Mann-Whitney U test. 2019-nCoV=2019 novel coronavirus. ICU=intensive care unit.

NOTAS ACLARATORIAS

Chaolin Huang, et al. Clinical features of patients infected with 2019 novel coronavirus in Wuhan, China.Lancet Vol 395 February 15, 2020

PRESENTACIÓN TABULAR

Actividad 3:

605 casos positivos de COVID – 19 en el Perú hasta el 11 de abril del 2020, fueron clasificados de acuerdo a la comorbilidad.

Proponer el título de la tabla

El título se redactará contestando a:

- ¿Qué?: distribución de casos positivos de COVID - 19,
- ¿Cómo?: según comorbilidad,
- ¿Dónde?: en el Perú,
- ¿Cuándo?: 11 de abril del 2020

Tabla 1.

Distribución de casos positivos de COVID - 19, según comorbilidad.

Perú-2020*

Tabla 1.
Distribución de casos positivos de COVID - 19, según comorbilidad. Perú-2020*

Comorbilidad	Frecuencia	Porcentaje
Diabetes Mellitus	236	39.0
Enfermedad Cardiovascular	287	47.4
Enfermedad Pulmonar Crónica	32	5.3
Enfermedad Renal	29	4.8
Cáncer	21	3.5
Total	**605**	**100.0**

*Fuente: Centro Nacional de Epidemiología, Prevención y Control de Enfermedades – MINSA. Corte 11 de abril 24 horas

Tabla 2
Distribución de casos positivos de COVID - 19, según etapa de vida y letalidad. Perú- 2020*

	Etapas de Vida					
Letalidad	Niño (0-11 años)	Adolescente (12-17 años)	Joven (18-29 años)	Adulto (30-59años)	Adulto Mayor (60 a mas años)	**Total**
Si	3	0	2	62	126	193
No	210	129	1446	4360	1181	7326
Total	213	129	1448	4422	1307	7519

*Fuente: Centro Nacional de Epidemiología, Prevención y Control de Enfermedades – MINSA. Corte 11 de abril 24 horas

Tabla 3
Distribución de casos positivos de COVID - 19, según etapa de vida y letalidad. Perú- 2020*

	Etapas de Vida											
	Niño (0-11 años)		Adolescente (12-17 años)		Joven (18-29 años)		Adulto (30-59años)		Adulto Mayor (60 a mas años)		Total	
Letalidad	n	%	n	%	n	%	n	%	n	%	n	%
Si	3	1.4	0	0.0	2	0.1	62	1.4	126	9.6	193	2.6
No	210	98.6	129	100.0	1446	99.9	4360	98.6	1181	90.4	7326	97.4
Total	213	100.0	129	100.0	1448	100.0	4422	100.0	1307	100.0	7519	100.0

*Fuente: Centro Nacional de Epidemiología, Prevención y Control de Enfermedades – MINSA. Corte 11 de abril 24 horas

Ejemplo de clasificación de datos según variable continua

123	116	137	147	132	115	120	132	141	130
127	113	140	135	120	153	106	138	117	150
153	125	143	126	143	121	123	135	120	138

1.- Determinar la amplitud del conjunto de datos (Valor máximo menos el valor mínimo), más una unidad de medida

$$A = (Vmax - Vmin) + 1$$

$$A = (153 - 106) + 1 \quad = 48$$

Nota: Si los valores máximo y mínimo están expresados hasta decimales, se incrementará un décimo (0.1).
Si Vmax=71.4 y V min=30.2, la amplitud sería

$$A=(153.7 – 106.2) + 0.1$$

Ejemplo de clasificación de datos según variable continua

2.- Determinar la amplitud del intervalo de clase

$$C = \frac{A}{K} \qquad C = \frac{48}{6} = 8$$

C = Amplitud del intervalo de clase, A = amplitud del conjunto de datos, K = número de clases

Para determinar K , podemos emplear la fórmula de Sturges

K= 1 + 3.322 log N

Para el ejemplo

K= 1 + 3.322 log (30) =5.9 Por lo que podríamos considerar que sean 5, 6, 7 número de clases

Ejemplo de clasificación de datos según variable continua

3.- Construir los intervalo de clase

El Vmin es el límite inferior de la primera clase y su respectivo límite superior será Vmin + (C – 1)

El límite inferior de la segunda clase es el límite superior de la primera clase más uno y el respectivo límite superior será igual al límite inferior mas (C – 1)

Así sucesivamente hasta completar el número de clases

	+ (8-1)			+ (8-1)	
106	-	113	130	-	137
114	-	121	138	-	145
122	-	129	146	-	153

Ejemplo de clasificación de datos según variable continua

3.- Construir los intervalo de clase

106 – 113

114 – 121

122 – 129

130 – 137

138 – 145

146 – 153

En la primera y última clase debe estar el Vmin y Vman respectivamente

Nota: Si los límites están expresados hasta decimales, entonces el límite superior de la primera clase es V min + (C – 0.1), si esta expresado hasta centésimas será V min + (C – 0.01)

Ejemplo de clasificación de datos según variable continua

4.- Clasificación de los datos de una variable cuantitativa

	f_i	F_i	h_i%	H_i%
106 – 113	2	2	6.7	6.7
114 – 121	7	9	23.3	30.0
122 – 129	5	14	16.7	46.7
130 – 137	6	20	20.0	66.7
138 – 145	6	26	20.0	86.7
146 – 153	4	30	13.3	100.0

Tabla 1
Distribución de pacientes según dosaje de glucosa. Hospital Nacional Dos de Mayo. Lima, Enero-2019

Dosaje glucosa	f_i	F_i	h_i%	H_i%	Límites reales	Marca de clase
106 - 113	2	2	6,7	6,7	105.5 – 113.5	109.5
114 - 121	7	9	23,3	30,0	113.5 – 121.5	117.5
122 - 129	5	14	16,7	46,7	121.5 – 129.5	125.5
130 - 137	6	20	20,0	66,7	129.5 – 137.5	133.5
138 - 145	6	26	20,0	86,7	137.5 – 145.5	141.5
146 - 153	4	30	13,3	100,0	145.5 – 153.5	149.5
Total	30		100,0			

PRESENTACIÓN GRÁFICA

Un *gráfico estadístico* es la *representación proporcional* del conjunto y de subconjuntos de datos por medio de figuras geométricas, diagramas o figuras.

El objetivo de un gráfico es dar una impresión visual de los datos para una rápida y fácil comprensión de las características de las variables o de sus relaciones.

El *tipo de gráfico* que se utilice depende de:

- el tipo de variable,
- qué es lo que se quiere mostrar,
- para qué, y
- para quiénes.

VARIABLES CUALITATIVAS:

Gráfico de barras:

- Simples → Una variable
- Compuestas→ Dos variables
- Superpuestas→Dos variables

- Gráfico de sectores circulares→ Una variable

VARIABLES CUANTITATIVAS:

Histograma

Gráfico de dispersión

Caja y Bigote

Gráfico 1
Casos positivos de COVID-19, según comorbilidad. Perú- 2020

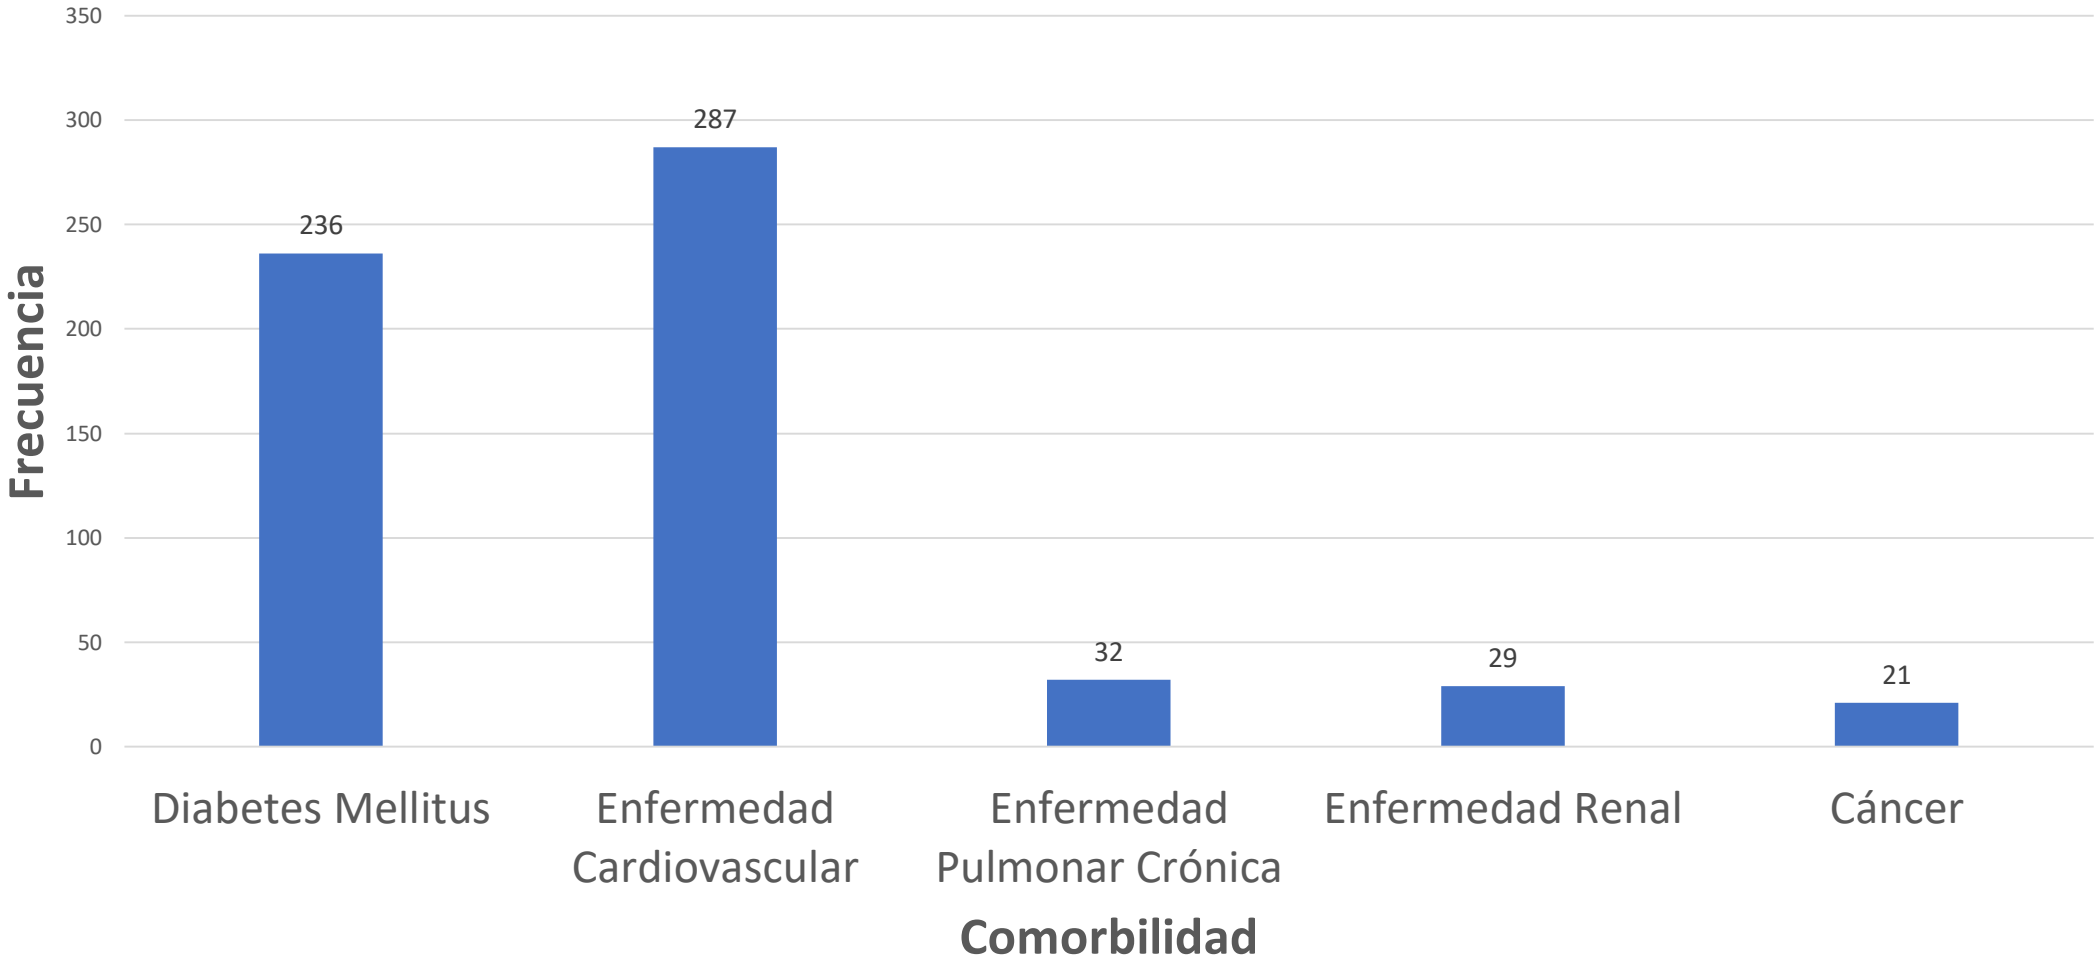

Fuente: Tabla 1

Gráfico 2
Casos positivos de COVID - 19, según etapa de vida y letalidad.
Perú-2020

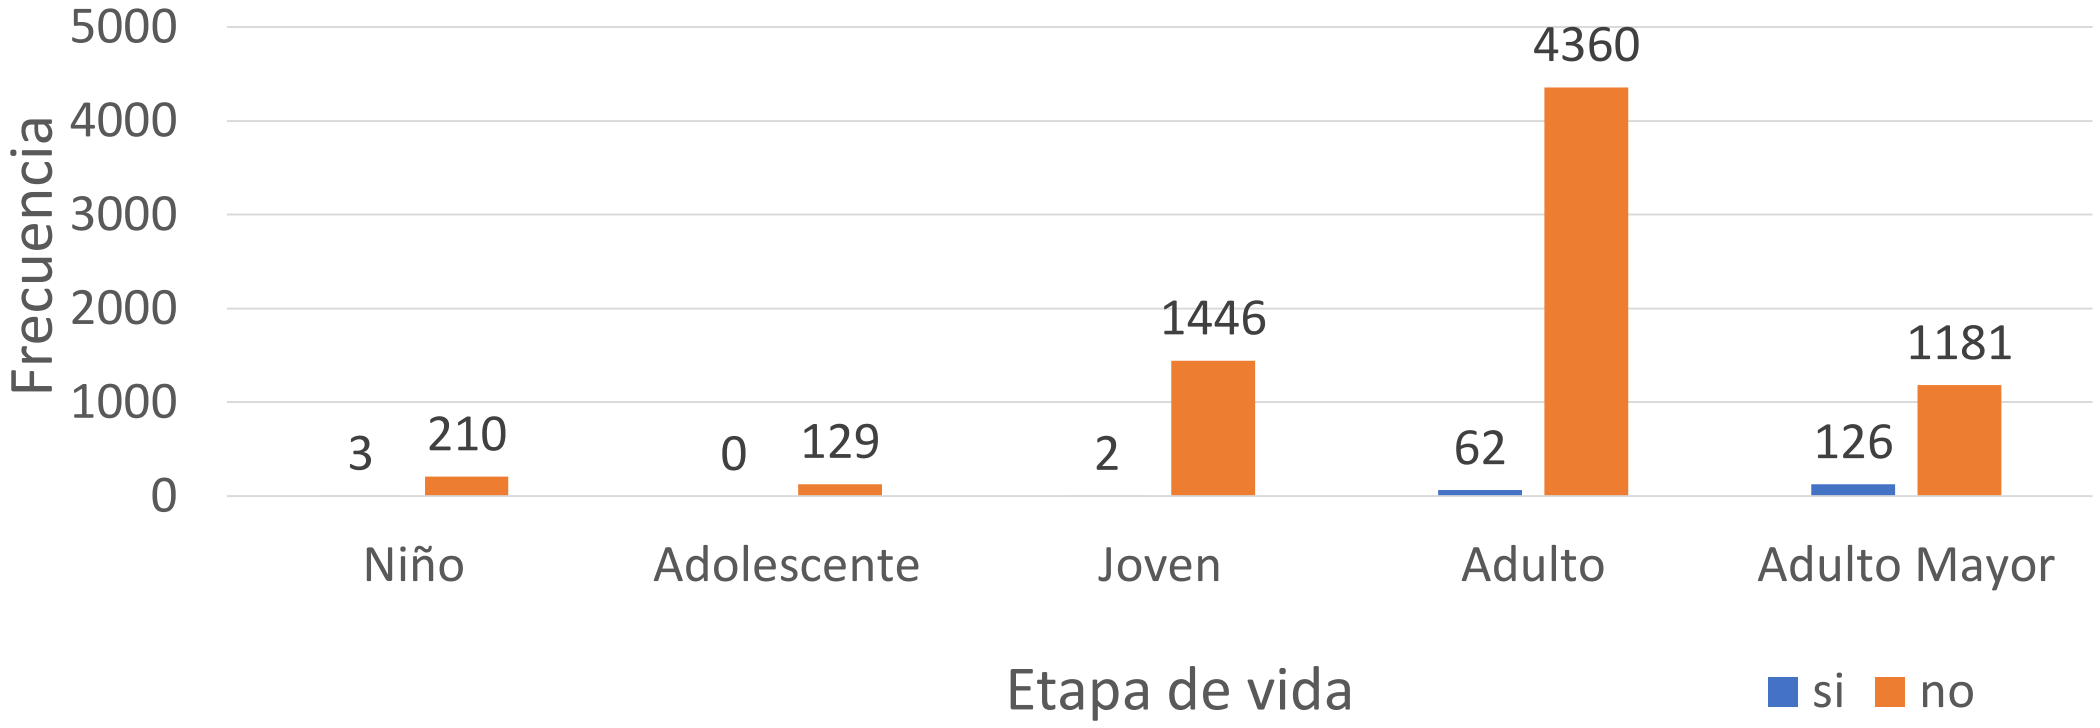

Fuente: Tabla 2

Gráfico 3
Casos positivos de COVID - 19, según etapa de vida y letalidad. Perú-2020

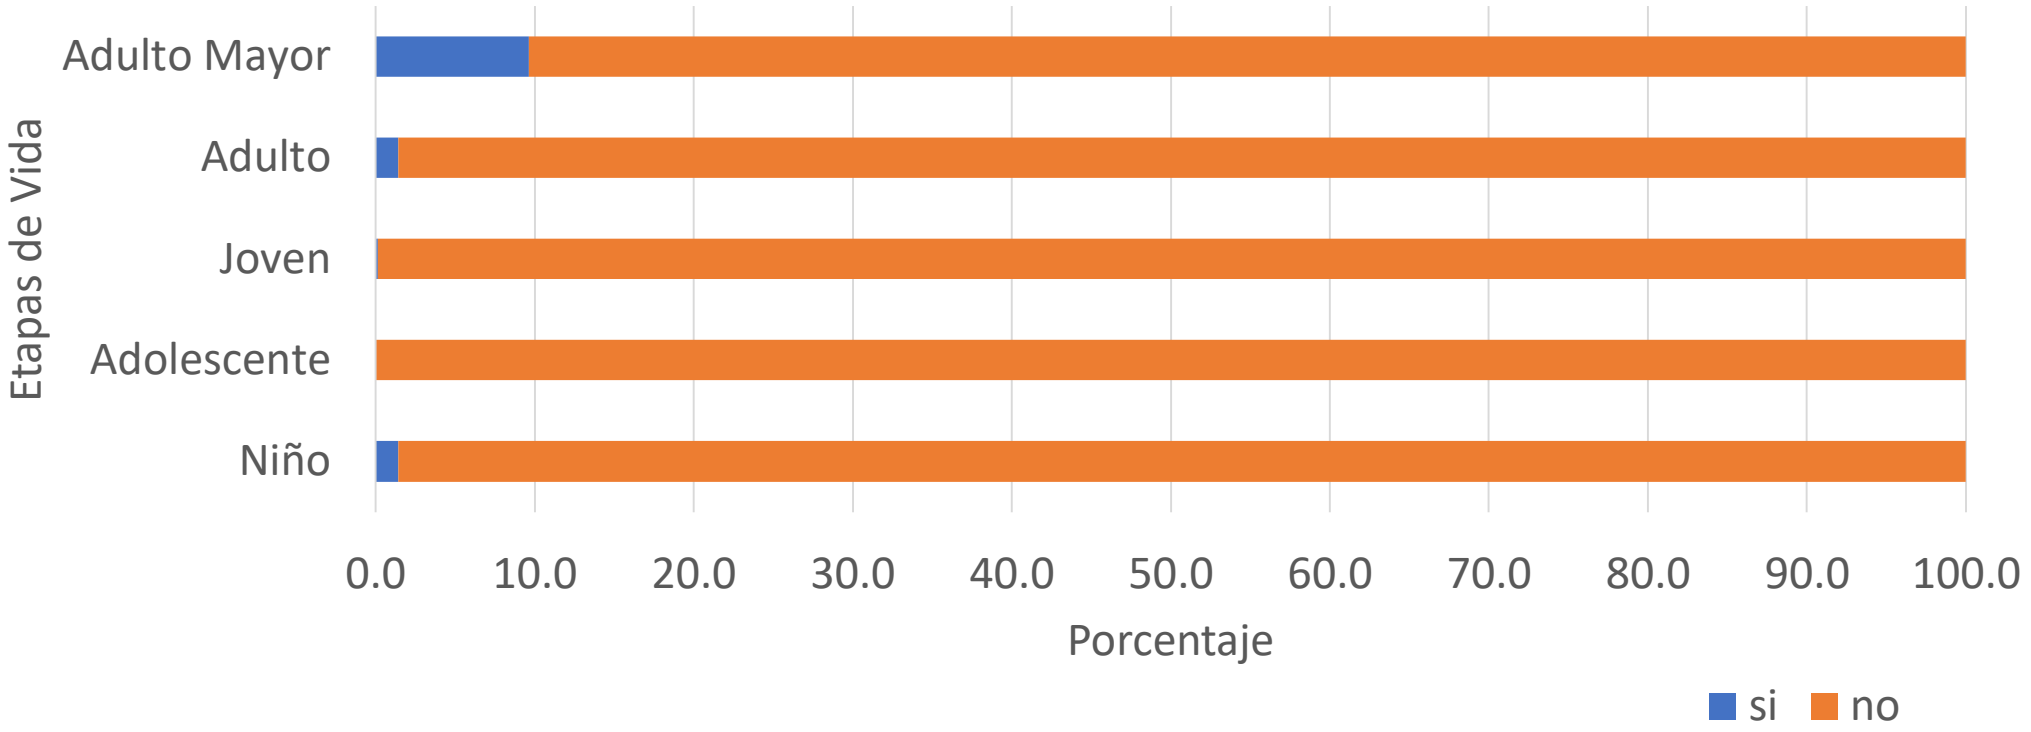

Fuente: Tabla 3

Gráfico 4
Casos positivos de COVID-19, según comorbilidad. Perú-2020

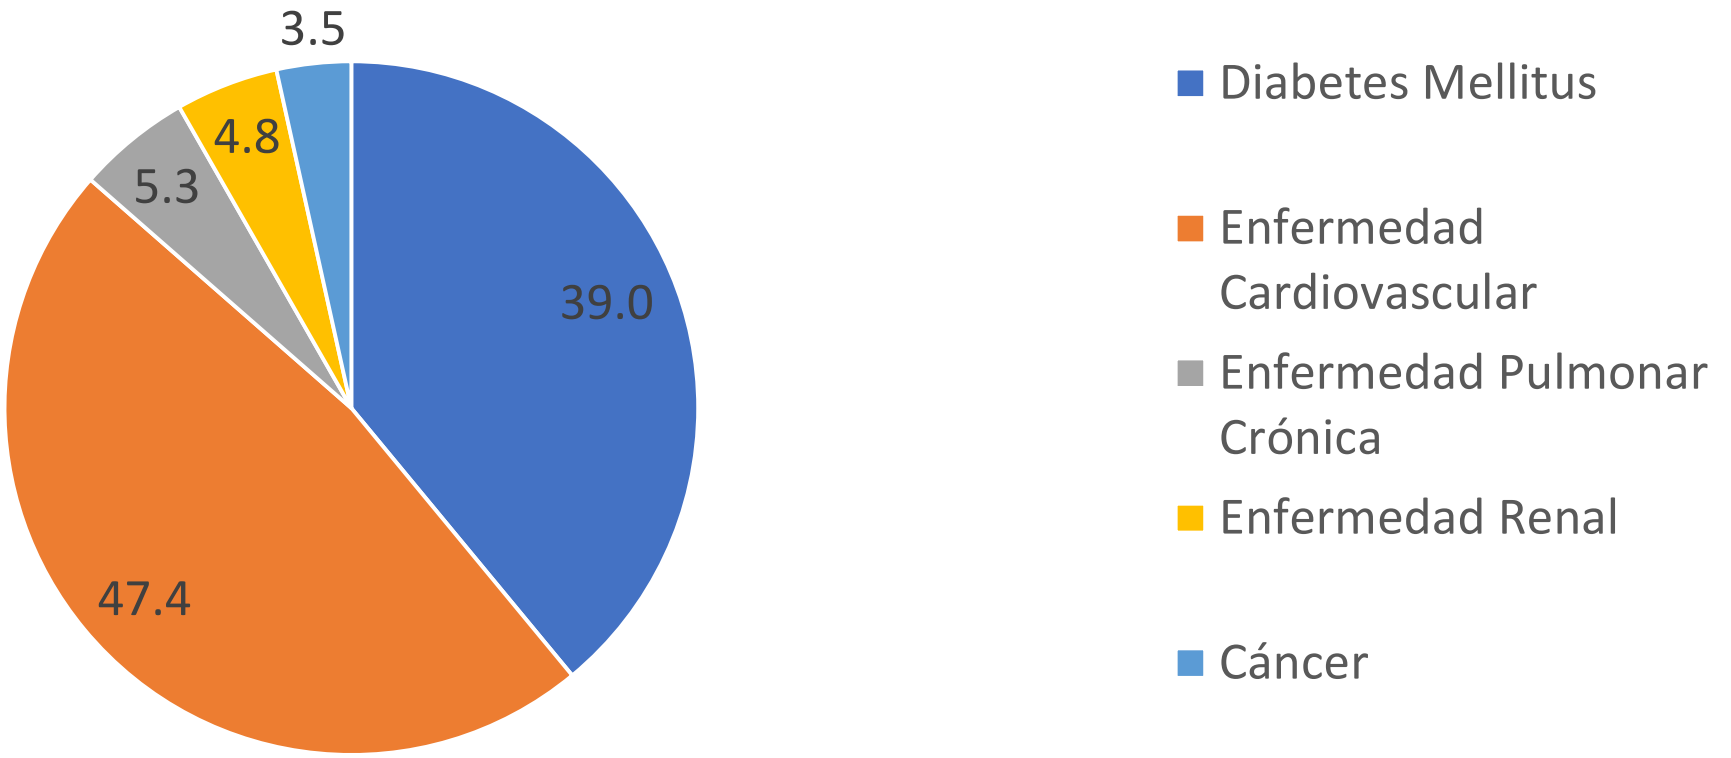

Fuente: Tabla 1

Gráfico 1
Pacientes según dosaje de glucosa.
Hospital Nacional Dos de Mayo. Lima, Enero-2019

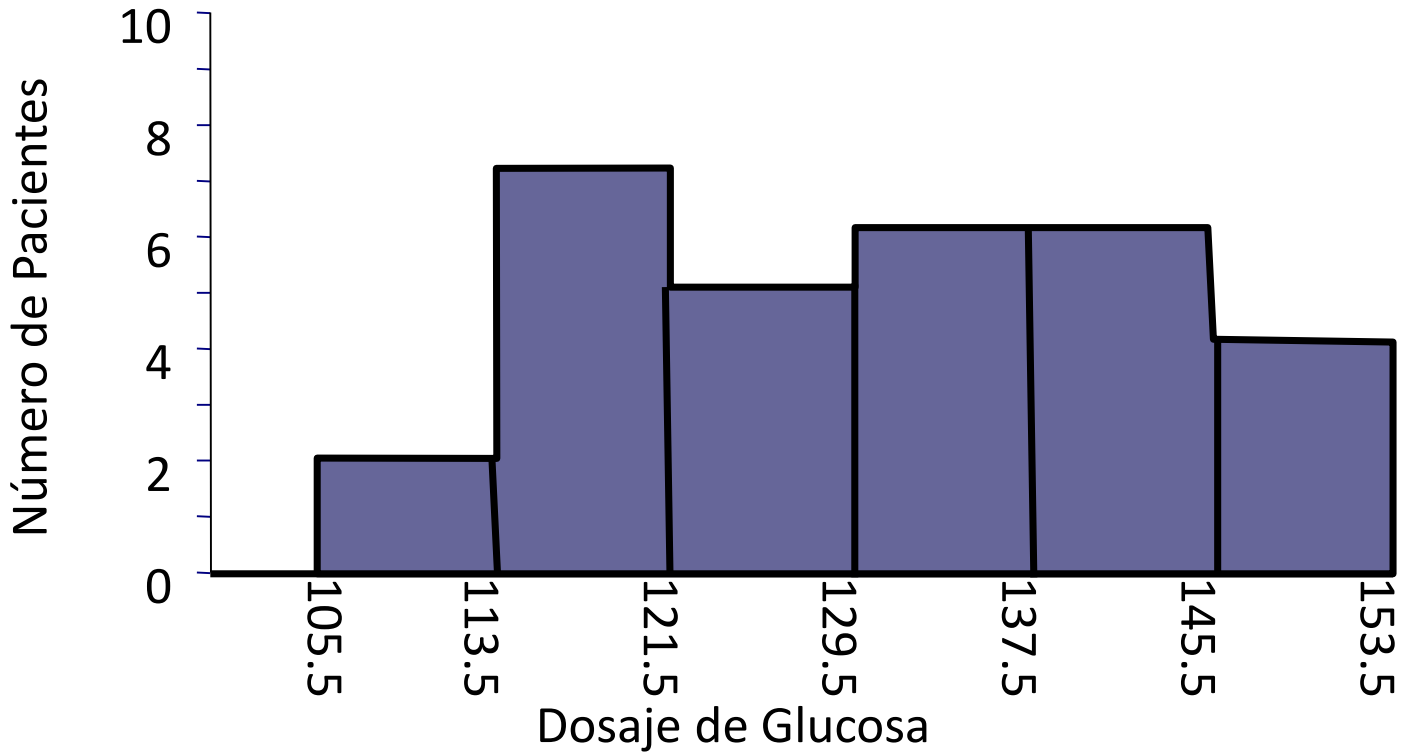

Fuente: Tabla de distribución de frecuencias …

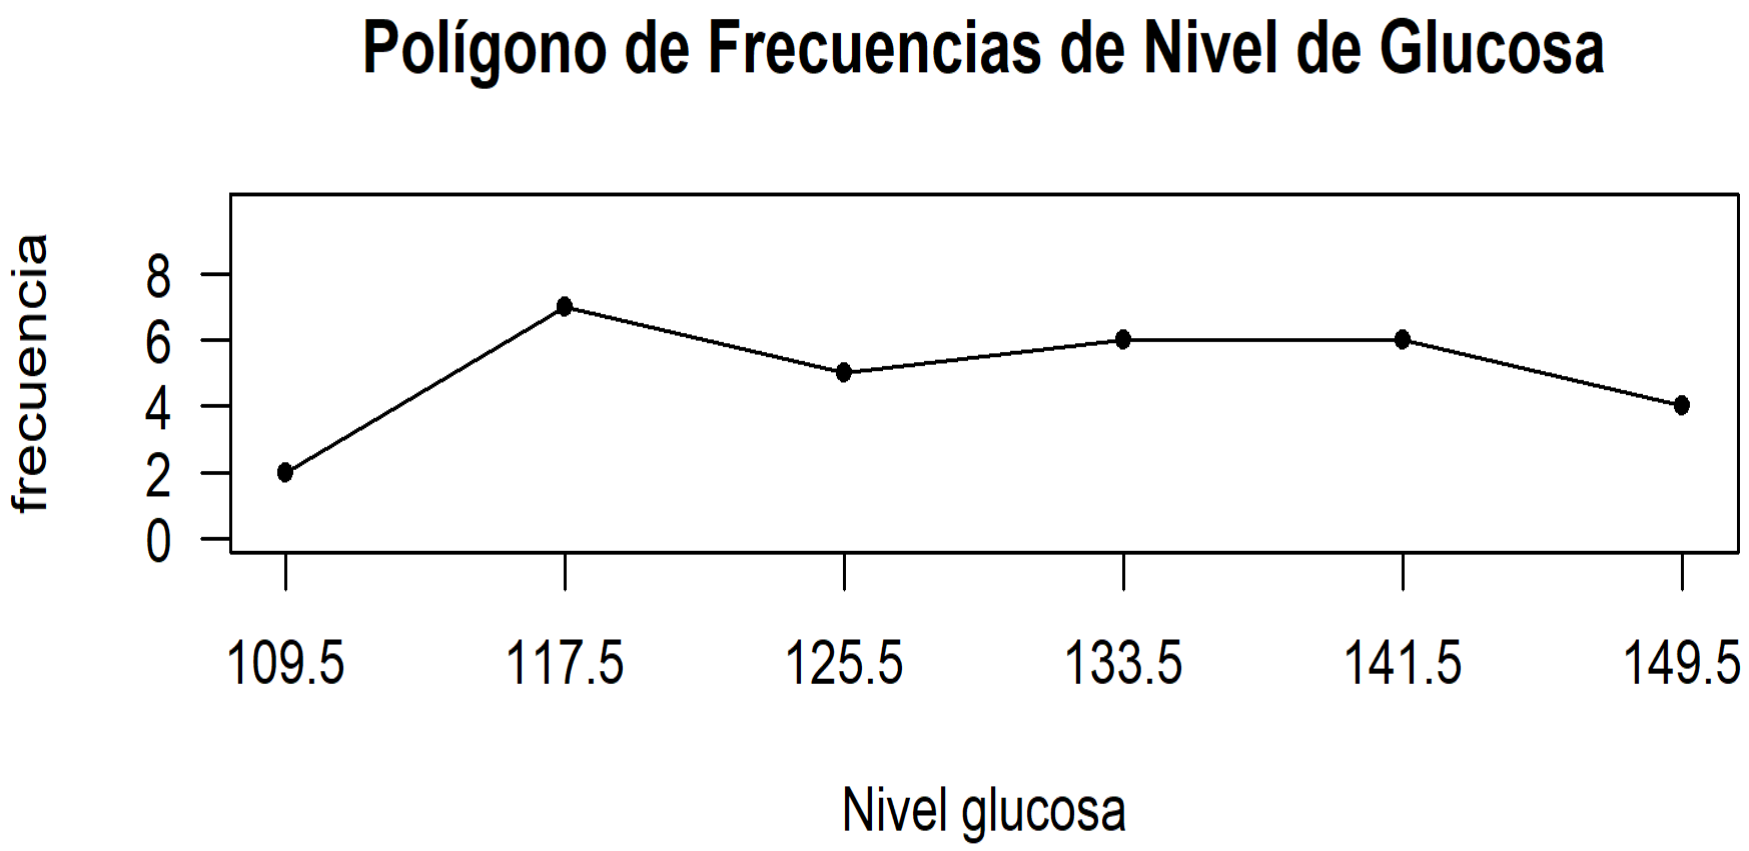
Polígono de Frecuencias de Nivel de Glucosa
frecuencia
0
2
4
6
8
109.5
117.5
125.5
133.5
141.5
149.5
Nivel glucosa

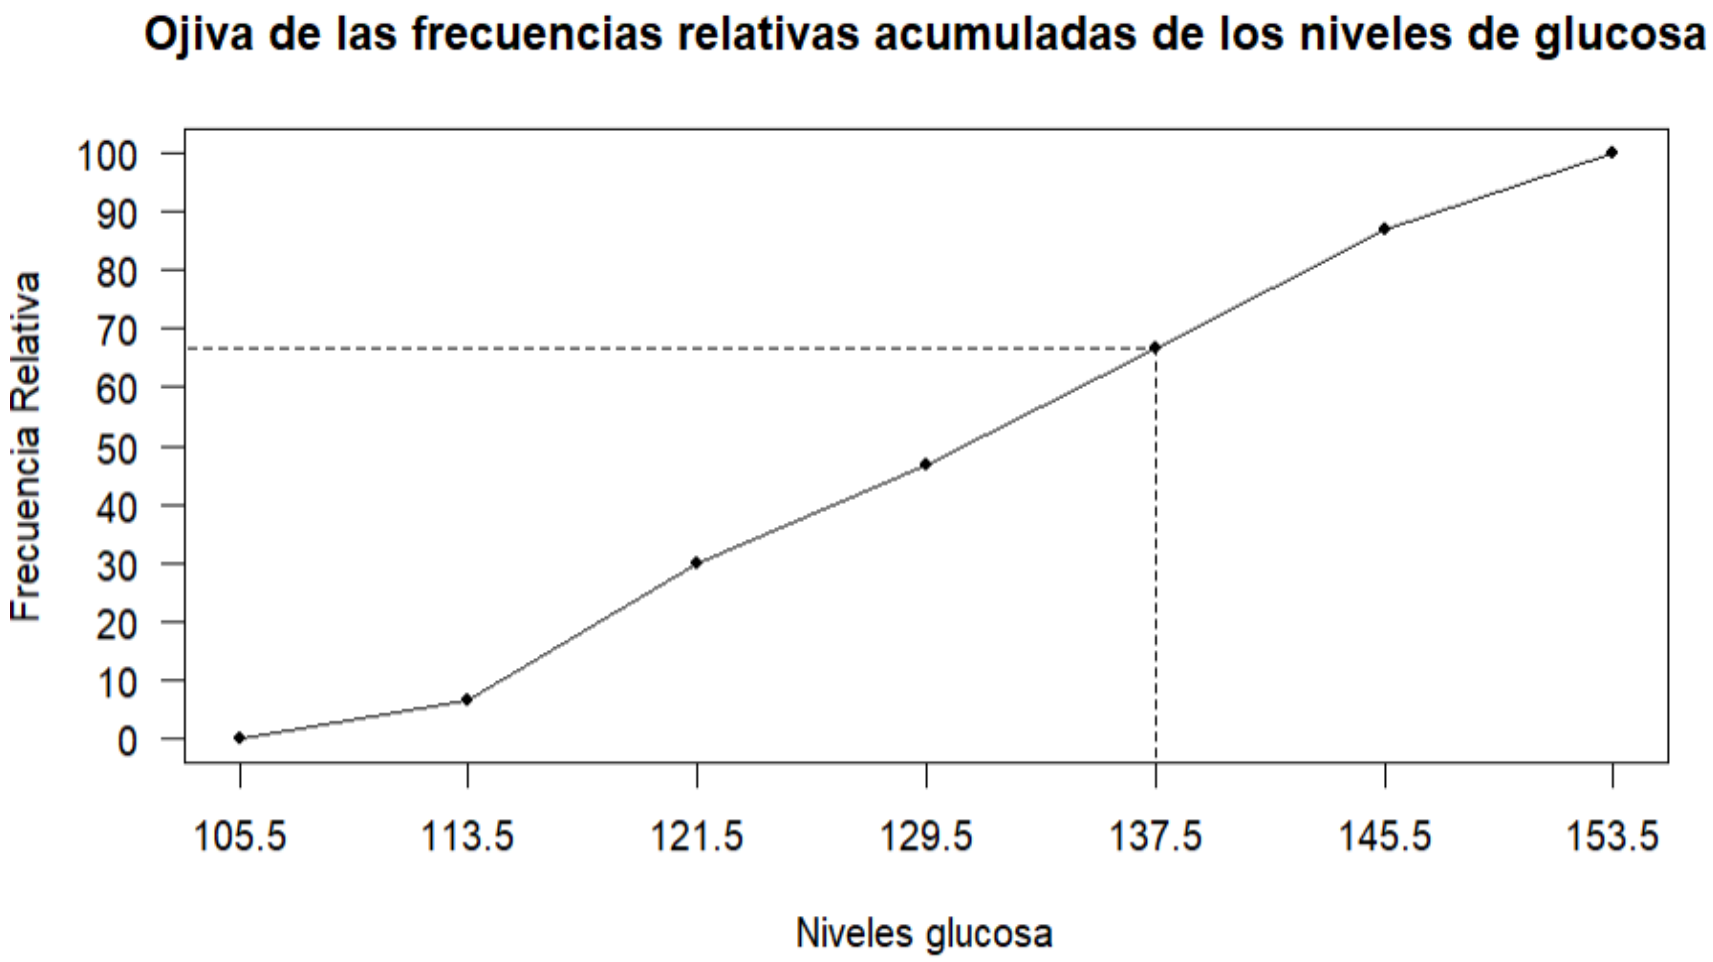
Ojiva de las frecuencias relativas acumuladas de los niveles de glucosa
Frecuencia Relativa
100
90
80
70
60
50
40
30
20
10
0
105.5
113.5
121.5
129.5
137.5
145.5
153.5
Niveles glucosa

GRÁFICO DE CAJA Y BIGOTE (BOX PLOT)

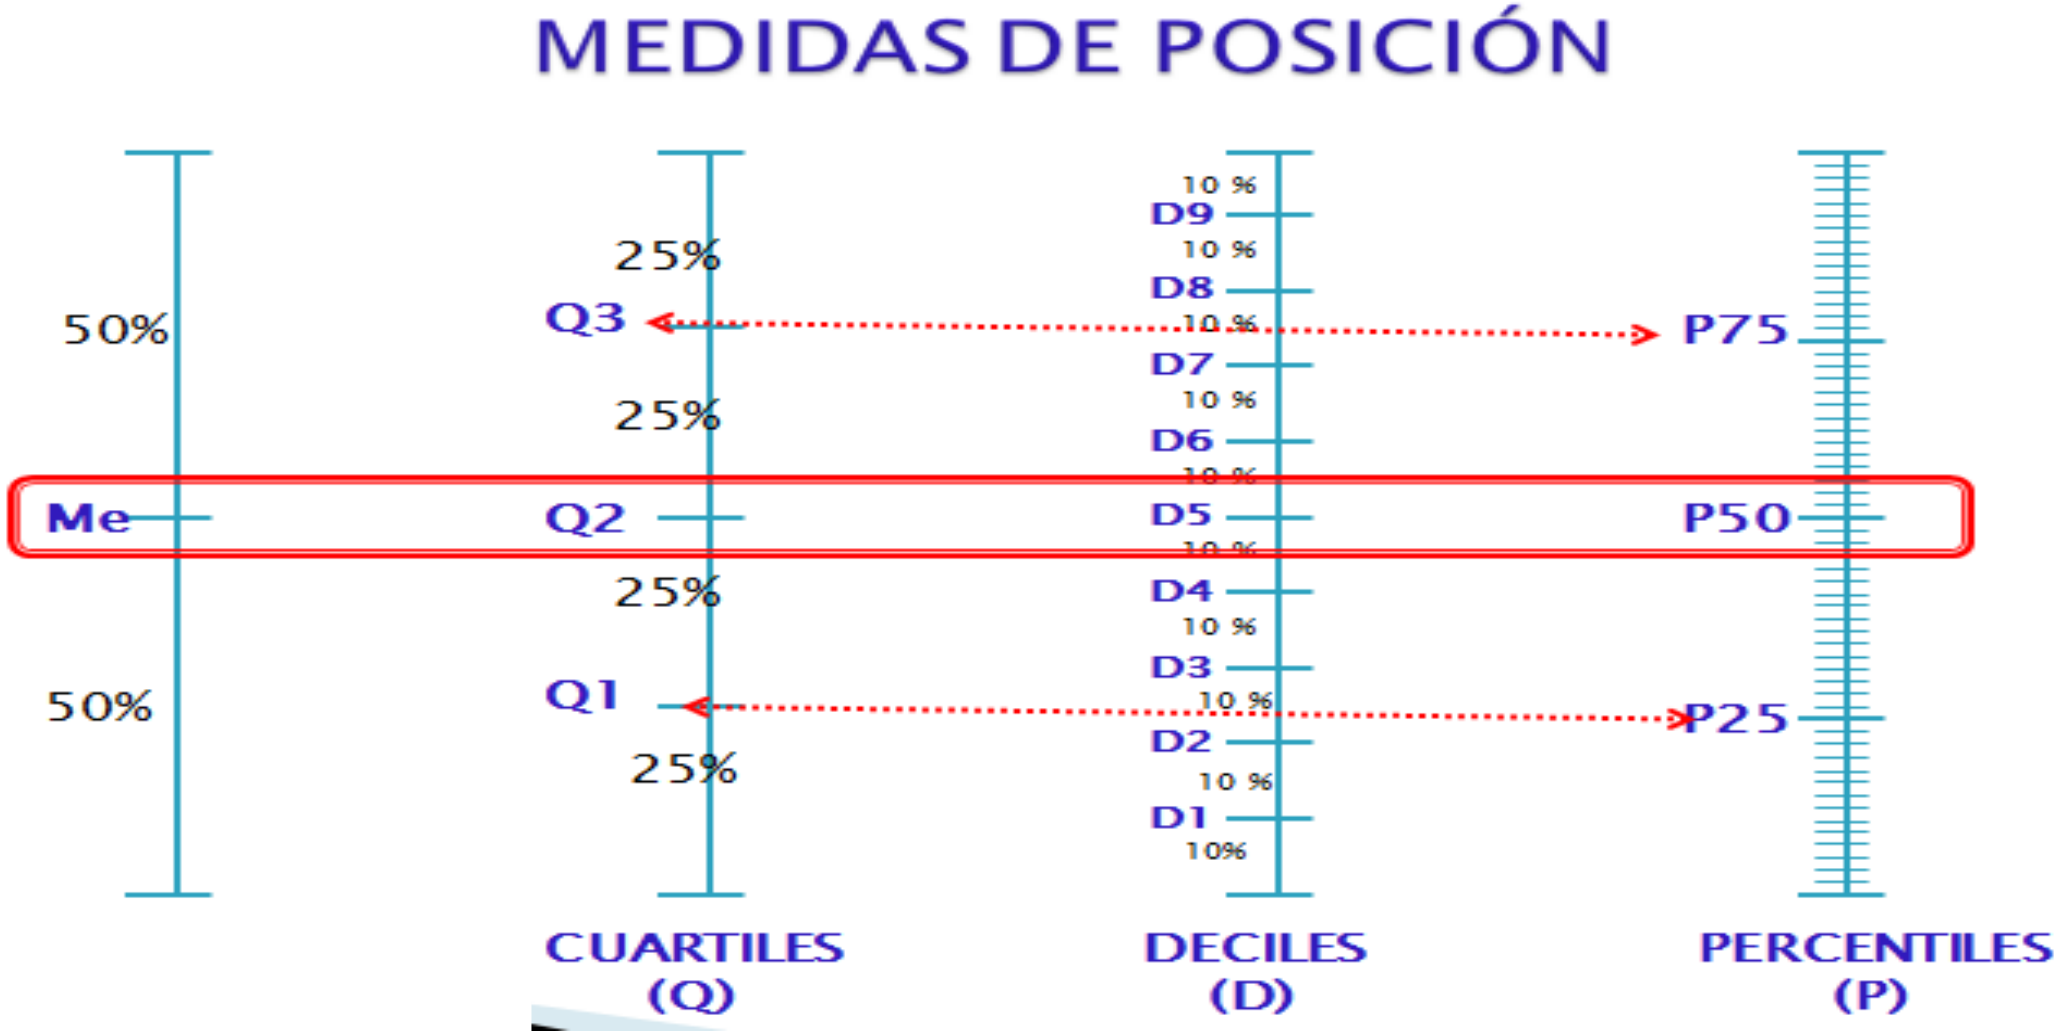

GRÁFICO DE CAJA Y BIGOTE (BOX PLOT)

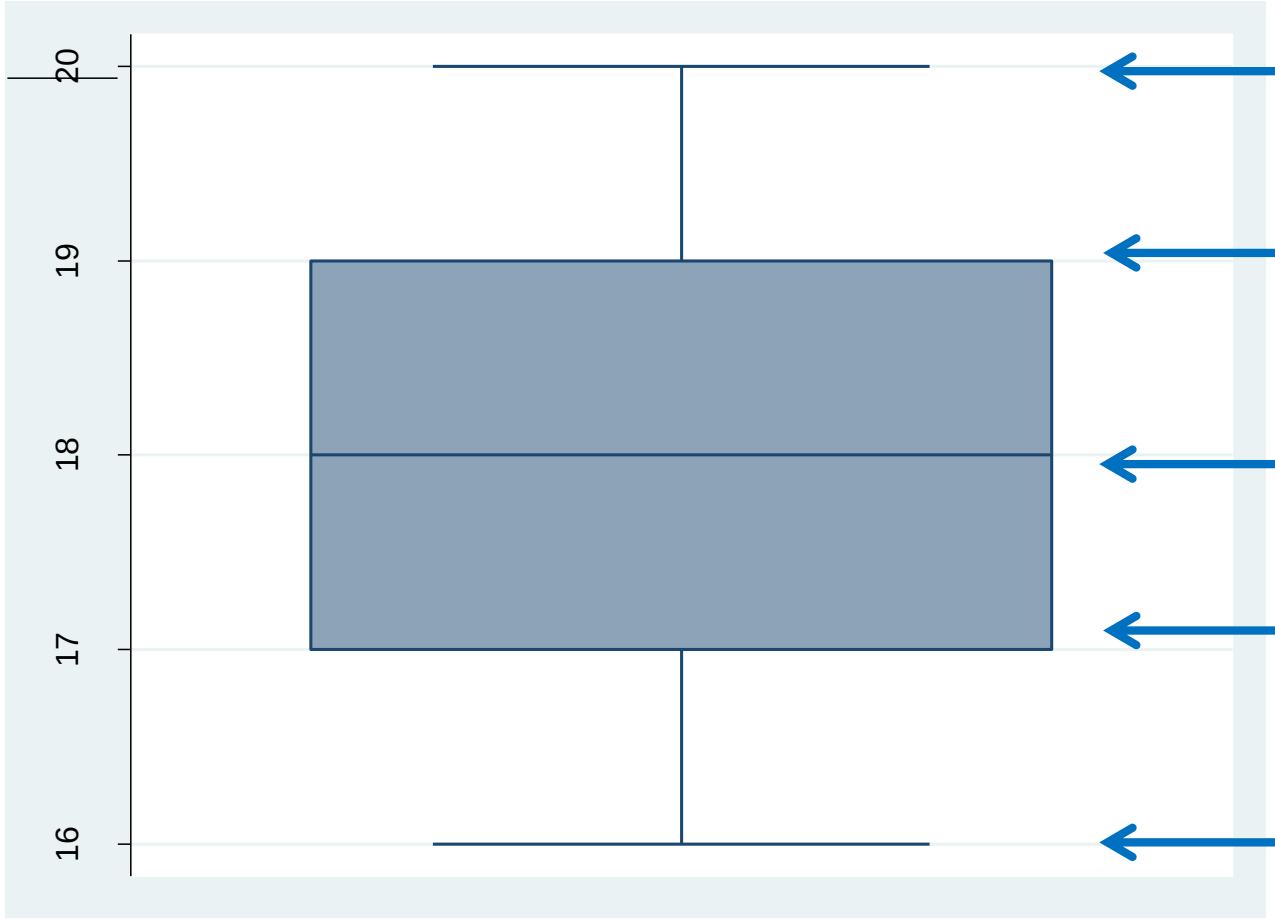

$Q_3+1.5(Q_3 - Q_1)$

Q_3

Q_2= MEDIANA

Q_1

$Q_1-1.5(Q_3 - Q_1)$

Un investigador tiene interés en evaluar si diferentes dosis de atropina producen diferentes efectos en la disminución del flujo salival.

Aplicó 4 dosis diferentes y midió el flujo salival correspondiente a cada dosis, expresando la disminución, en porcentaje de disminución.

Aplicó las dosis en 16 animales de laboratorio en cuatro momentos distintos.

Comportamiento del flujo salival según dosis

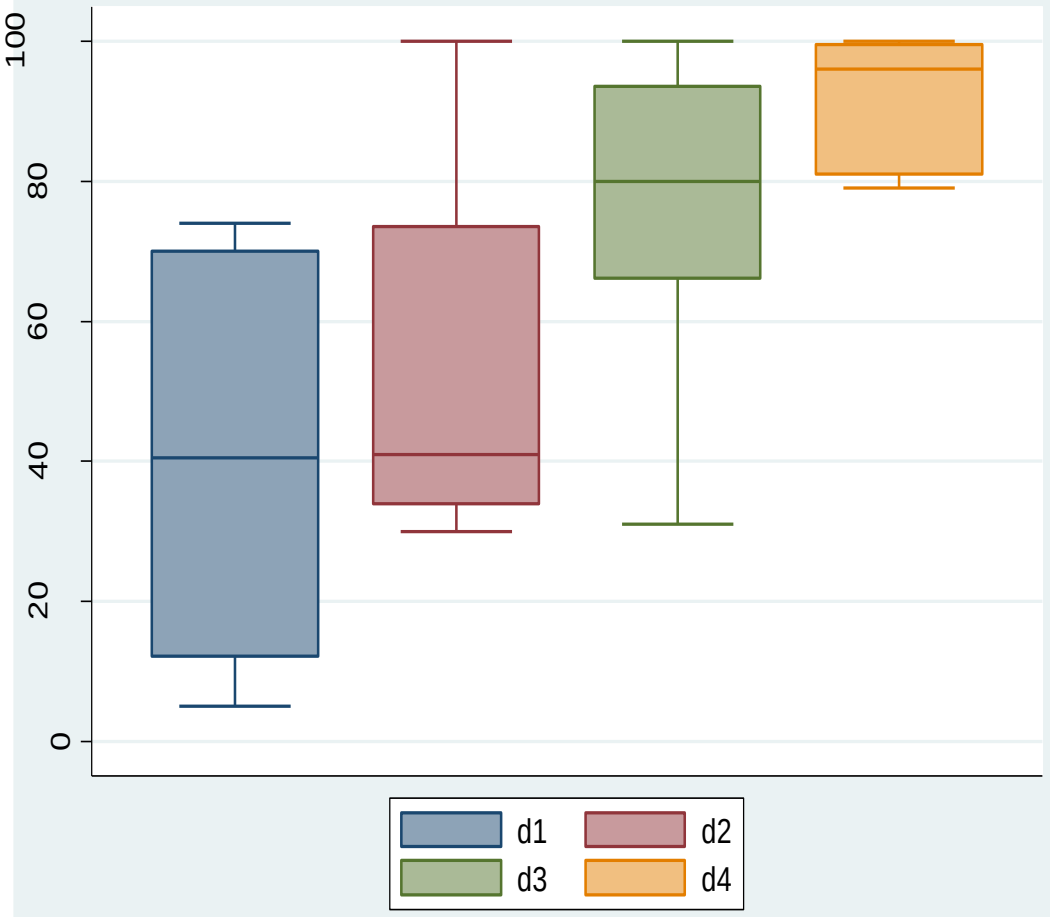

GRÁFICO DE DISPERSIÓN

Describe la relación entre dos variables cuantitativas.
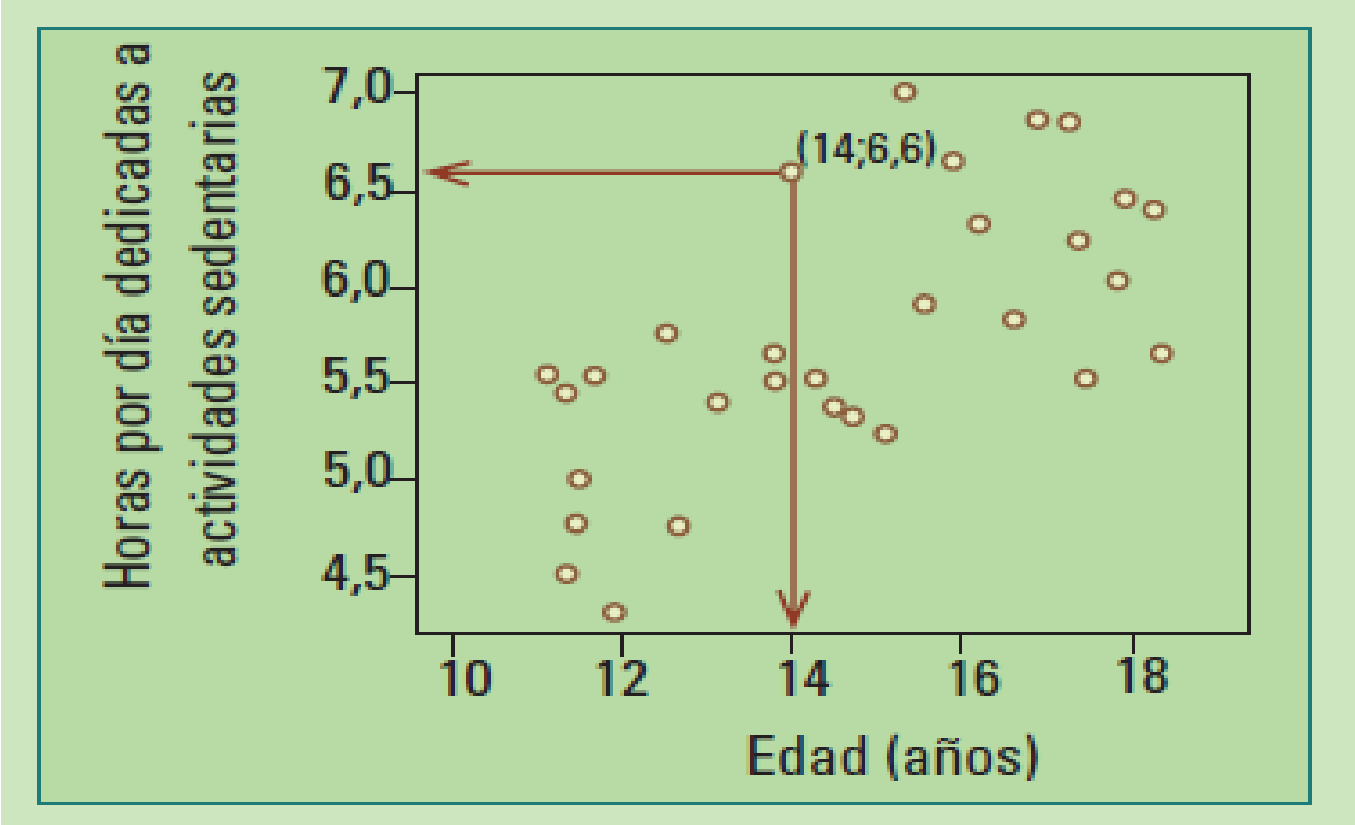
Cada **punto** corresponde a **un par de valores** (uno para cada variable), medidos en la misma unidad de análisis.